


Aprendizaje Bayesiano

→ capítulo 6 libro

[La ausencia de evidencia
no es evidencia de ausencia]



- Observar su entorno y aprende de él

CARACTERÍSTICAS → capacidad de adaptarse y procesar datos contradictorios, cas

Alg. Bayesianos → decisiones difusas (se manejan con Prob.)

Inferencia estadística es :

¿cómo encontrar o sentir de algo que parece cosas un cierto orden?

- David Hume → idea: los milagros son imposibles
↳ 'es imposible romper las leyes de la naturaleza'
- Richard Price →

conclusión :

Razonamiento Bayesiano :

- ④ Ningún evento puede tener probabilidad $\phi \circ 1$
(no es correcto)

- La intuición como inferencia estadística
⇒ es muy difícil creer que un evento no va a pasar nunca

Resumen Prob.

- Eventos independientes $(A, B) \Rightarrow P(A \cap B) = P(A) \cdot P(B)$
- Prob. condicional : $P(A|B) = \frac{P(A \cap B)}{P(B)}$
- Prob. total () :

Ejemplo - Covid - Probabilidad de covid en pobl. = 0,001

$$P(\text{Prueba} = + | \text{Covid} = +) = 0,85$$

$$P(\text{Covid} = +) = 0,001$$

Ejemplo - Amueblar de la experiencia

#	Tiempo	Temp	Humedad	Viento	Juego
.	Soleado				
:	Nuboso				
:	Lluvioso				
:					

Quiero predecir si la persona va a jugar al golf

$$\text{un día } < s, t, a, f > \rightsquigarrow P(< s, t, a, f > | \text{si})$$

→ Saco prob. a partir de los datos que tengo

$$\text{ej: } P(\text{jugar} = \text{Si}) = 9/14 \rightarrow \text{para el conj. de octeto que}$$

$$P(\text{tiempo} = f | \text{jugar} = \text{Si}) = 3/9 \text{ tengo}$$

$$P(\text{humedad} = |) =$$

:

Usando las form. prob. Cond →

$$P(\text{soleado} | \text{si}) = \dots \dots \dots$$

$$P(\text{soleado} | \text{no}) =$$

$$P(\text{soleado} | \text{si}) < P(\text{soleado} | \text{no})$$

→ le ^{mejor} respuestas en no

• se asume que las condic. del clima son independientes

en este caso h es si juego o no
y d la combinación del clima

Fórmula de Bayes

$$\Rightarrow P(h|D) = \frac{P(D|h)P(h)}{P(h)}$$

D = evidencia
h = hipótesis

Teo de Bayes:

Sea H un espacio de hipótesis y D un conj. de datos de entrenamiento

- $P(D|h) \sim^{prob}$

- $P(h|D) \sim$

↑
en la que
nos interesa
conocer

$$P(h|D) = \frac{P(D|h) \cdot P(h)}{P(D|h) \cdot P(h) + P(D|\neg h)}.$$

Hipótesis MAP y ML

Buscamos h que maximiza $P(h|D)$

- MAP $\rightarrow P(h|D) =$

⋮

$$h_{opt} = \max_{h \in H} \{ P(D|h) \cdot P(h) \}$$

Si asumimos hipótesis equiprob. $\rightarrow h_{opt} = \max_{h \in H} \{ P(D|h) \}$

CARACTERÍSTICAS

- Soporta datos con ruido
- Las implementaciones tienen un costo computacional alto

Fuertes:

- Ajustador n.
- Obra
-

→ cada vez que hay datos nuevos, podemos re-entrenar y volver a calcular los prob. para que sea más preciso

Dificultades:

- Conocer muchas probabilidades
- Hipótesis y distribuciones
- Costo computacional ($\approx \max P(\cdot | \cdot) \cdot P(\cdot)$)
 - ↳ depende de cant. de hipótesis y cant. de posibles valores de cada variable
 - ↳ gran límite

este es el que se usa

CLASIFICADOR SENCILLO (Naive Bayes)



simplifico -: independencia de atributos

Sea $\vdash \rightarrow \cdot$

$$\Rightarrow VNB = \max_{v_i \in V} \prod P(v_i | \cdot) \cdot P(\cdot)$$

Características:

+

+

→ La prob. de un atributo nula es 0 o 1 !!!

Acumulación de experiencias y certezas

¿Cómo estimar la prob. cuando tenemos pocos datos?

→ Esto genera prob. en los mult. de prob.

Sol: TÉCNICA DE M-ESTIMADOR

$$= \frac{c + m \cdot p}{n + m}$$

$p =$
 $m =$ tamaño de la muestra

→ Se agregan valores 'ficticios' adicionales

hay que determinar m

ejemplos de Laplace

(m=1) - eliminado

atributo	datos	Frecuencia	
	n		
			m=2 m=5

Resumen

- Prob. Cond $\rightarrow P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$ Probabilidad a priori
- Fórmula de Bayes $\rightarrow P(h|D) = \frac{P(D|h) \cdot P(h)}{P(D)}$
- Hipótesis MAP $\rightarrow H_{MAP} = \underset{h \in H}{\operatorname{argmax}} \underset{\text{L max.}}{\cdot} P(D|h) \cdot P(h)$
- Naive Bayes $P(a_1, \dots, a_n | H) = P(a_1 | h) \times \dots \times P(a_n | h)$
- m-estimador $\rightarrow \underset{h \in H}{\operatorname{argmax}} P(h) \cdot \prod P(a_i | h)$
 - ↳ técnica para evitar que las prob. den 0
 - ⇒ aumento efecto muestral $f = \frac{1}{n} \rightarrow f = \frac{1 + \frac{1}{n+m}}$

TAREA 2 - Predicción de Palabras

- usar alg. Naive Bayes


simplificaciones [

- frase completa: medimos todo (completo)
⇒ modifica la func. bayesiana

Solo quedarse con los
menos jefes
local nombre y tecno

n-gramas

- writer loops
→ no más de 10 min



① Preprocesar los datos

- palabras en lista
- y minúsculas
- stopwords

} PDK
lo pose

② Crear el modelo con palabras del diccionario

③ Construir el modelo

ej: mi hijo vendrá por _____



para cada palabra del
diccionario cálculo:

ej: mochila

N-últimas
palabras
↑
n-gramas

$$P(\text{mochila}) \times P(\text{lo} | \text{mochila}) \\ \times P(\text{nijo} | \text{mochila}) \times \\ P(\text{perdido} | \text{mochila}) \\ \times \dots$$

→ tomo la palabra con mayor
probabilidad

④ elegir criterio que nos cuando lee
prob el \emptyset
 \rightarrow justificarlo

⑤ $P[h \mid d]$

\hookrightarrow prob. h dado once d

Pseudocódigo

$$D = \{ \cdot, \cdot, \cdot, \cdot \}$$

horizonte = 4

$$h_MAP = \cdot, \cdot, \cdot$$

$$P_map = \emptyset$$

for h in P:

$$\text{prob} = P[h]$$

for d in D[-horizonte:] :

$$\text{prob} = \text{prob} \times PD[h].get(d, P.prob)$$

ej: $\frac{\text{cont. total}}{\text{palabras}}$



valor default

if prob > p-MAP:

$$h_map, P_map = h, \text{prob}$$

point + (h-map) \leftarrow palabra

recomendado

\rightarrow entregar cuando termino una frase

\hookrightarrow palabras nuevas ejear

(puede ser cada n-frases)

ej: lo

⑥ Ponez foco en el entrenamiento

⑦ Verificoz que aprendió

⑧ Asumimos que en el entrenamiento
aprenderon palabras

⑨ Use log!

Predictor de texto \leftarrow uso del alg.

Clasificador de Texto

→ uso del alg.

· clasificar textos en categorías

→ muchas palabras \Rightarrow prob. chicos

\Rightarrow WOP prob log.

→ considerando el orden de palabras

:

:

\Rightarrow Asumiendo ind. de palabras

↳ Reducir el tamaño del modelo

calcular $V_{NB} = \max_{v_j}$

:

problema \rightarrow

solt. \rightarrow óptimos log

prop:

$$\log(P(E) \cdot P(F)) = \log(P(E)) + \log(P(F))$$

\Rightarrow aplicar rango de valores

$$-\infty \leq \log(P(E)) \leq 0$$

↑
-prob
+prob

$\Rightarrow z_i \ a < b$

$$\Rightarrow \log(a) < \log(b)$$

$$\log\left(\prod_{j=1}^n P(v_j) \prod_{k=1}^m P(\beta_k | v_j)\right)$$
$$\log(P_{vg}) + \sum \log(P_{pk})$$

Otras simplificaciones:

- límites vocabulario
- eliminar palabras veces

?

?



decisiones que
hay que tomar
en los implemen-
taciones
(justificando)

Clasificadores de texto

- modelo sencillo
- se calcula rápido
- ⇒

Clasificadores Bayesianos optimos